



Notice technique de l'outil de validation automatique de l'ONM

Table des matières

1. Introduction.....	1
2. Schéma conceptuel	2
3. Modèle conceptuel des données	3
4. Les référentiels.....	4
a. Les groupes taxonomiques	4
b. Les territoires.....	4
c. Le référentiel de validation.....	4
d. Le référentiel des notes	4
e. Les référentiels d'identification.....	5
f. Les référentiels de présence.....	5
g. Les référentiels de période d'observation	5
h. Versioning des référentiels de notation	6
5. Les fonctions de calcul des notes	6
a. Note d'identification.....	6
b. Note de présence	6
c. Note de période d'observation.....	7
6. La fonction de traitement des notes de validation	7
7. La fonction centrale de validation d'une observation	10
8. La fonction globale de validation par séries	11
9. Le reporting	11

1. Introduction


L'outil de validation automatique des données de l'ONM est une combinaison de fonctions imbriquées que l'on va pouvoir appliquer à une observation après son intégration dans geonature via son identifiant interne (id_synthese). Il pourra donc s'appliquer à façon avec des scripts dédiés soit à un jeu de données entier, soit à un import ou à tout autre groupe de données défini.

Plusieurs conditions sont nécessaires à l'exécution de cette validation :


- Présence d'un UUID attaché à cette données (soit fourni soit généré lors de l'import)
- L'existence des référentiels nécessaires au calcul des notes (identification, présence et période d'observation)
- La présence du cd_ref de l'espèce rattachée dans l'un des groupes taxonomiques dédiés à la validation.

L'ensemble des tables, vues et fonctions citées dans cette notice sont dans le schéma **valid_auto** de la base de données geonature2db.

2. Schéma conceptuel



3. Modèle conceptuel des données



4. Les référentiels

a. Les groupes taxonomiques

Rappel : la validation des données se fait au niveau ESPECE uniquement. Les observations de sous-espèces sont donc affectées à l'espèce parente pour la validation. Pour cela nous avons créé la fonction **find_cdref_es**(cd_nom) dans le schéma taxonomie. Cette fonction renvoie pour tout cd_nom le cd_ref de l'espèce associée (rang « ES »).

Les groupes taxonomiques de la validation automatique sont définis via l'outil liste de Taxhub dans geonature. Une liste pour la validation peut contenir n'importe quel niveau taxonomique inférieur ou égal au rang "ESPECE".

Condition pour qu'une liste soit utilisée pour la validation automatique : le code liste doit commencer par « valid_auto »

La fonction **find_all_cdref_childs_liste**(id_liste) créée dans le schéma taxonomie permet, grâce à une requête récursive, de récupérer tous les cd_ref des taxons de rang « ESPECE » dans la descendance des taxons présents dans la liste.

Le référentiel des groupes taxonomiques est matérialisé dans la vue suivante : **v_cor_cdref_grp_valid_auto**(code_liste, cd_ref).

Note : S'assurer qu'aucune espèce ne soit présente dans plus d'une liste de validation.

b. Les territoires

Les territoires correspondent aux unités géographiques (id_type = 24) présents dans la table ref_geo.l_areas. Ils sont matérialisés dans la vue : **v_territoires_france**(area_code). Ils correspondent à « Métropole » et les différents territoires d'outre-mer.

c. Le référentiel de validation

Le référentiel de validation automatique est décrit dans le [guide méthodologique de la validation de l'ONM](#). Il définit, pour une observation, le statut de validation en fonction des 3 notes calculées : identification, présence et période d'observation. Il est présent dans la table **ref_valid_auto** (note_identification, note_presence, note_periode, valid_auto)

d. Le référentiel des notes

Celui-ci décrit les notes utilisées pour le calcul de la validation. Il s'agit de la table **ref_notes** (lib_note, code_note, id_note, type_note) où type_note est l'une des valeurs identification, période et présence.

e. Les référentiels d'identification

Les référentiels d'identification se présentent sous forme de tables ayant le nom : **ref_identification_<code_liste_taxo>**. (Exemple : ref_identification_valid_auto_chiro). Le code_liste_taxo étant le code_liste du groupe taxonomique définit pour la validation (chapitre 2.a.)

Les référentiels contiennent pour chaque territoire les notes de F0 à F4 pour chaque cd_ref/technique d'observation.

Les tables doivent avoir les champs suivants :

cd_ref (num), **id_nomenclature_obs_technique** (num), **note_identification** (txt) et **code_territoire** (txt).

f. Les référentiels de présence

Les référentiels de présence se présentent sous forme de tables ayant le nom : **ref_presence_<code_liste_taxo>**. (Exemple : ref_presence_valid_auto_chiro). Le code_liste_taxo étant le code_liste du groupe taxonomique définit pour la validation (chapitre 2.a.)

Les référentiels contiennent pour chaque territoire les notes de P1 à P5 pour chaque cd_ref/géométrie de référence. La géométrie de référence est par défaut la maille 10x10 mais celle-ci peut être modulée dans les paramètres selon le territoire.

Les tables doivent avoir les champs suivants :

cd_ref (num), **area_code** (txt), **note_presence** (txt) et **code_territoire** (txt).

g. Les référentiels de période d'observation

Les référentiels de périodes d'observation se présentent sous forme de tables ayant le nom : **ref_periode_<code_liste_taxo>**. (Exemple : ref_presence_valid_auto_chiro). Le code_liste_taxo étant le code_liste du groupe taxonomique définit pour la validation (chapitre 2.a.)

Le référentiel contient pour chaque territoire les périodes favorables à l'observation. La période est définie par une date de début et une date de fin au format doy (day of year) de 1 à 366.

Les tables doivent avoir les champs suivants :

cd_ref (num), **date_obs_favorable_inf** (num), **date_obs_favorable_sup** (num) et **code_territoire** (txt).

Il est convenu que lorsqu'au moins une période favorable est définie, le reste de l'année est considérée comme période non favorable.

h. Versioning des référentiels de notation

Il est souhaitable de garder l'historique des référentiels lorsque ceux-ci sont mis à jour. Il est donc envisagé d'en copier une version avec le numéro de version dans le nom et de stocker dans une table les noms de tous les référentiels passés avec la période d'application (date_min, date_max). Ceci permettra de retrouver avec la date de validation quel référentiel a été utilisé lors d'une validation automatique. (A développer)

5. Les fonctions de calcul des notes

Les fonctions de calcul de notes sont toutes construites sur le même format. Elles se nomment :

fn_valid_auto_<type_de_note>(p_id_synthese,p_code_liste,p_code_territoire, p_params). Les paramètres envoyés aux fonctions sont :

- p_id_synthese : l'id_synthese de l'observation à noter.
- p_code_liste : le code du groupe taxonomique rattaché à l'observation.
- p_code_territoire : le code du territoire de l'observation.
- p_params jsonb : paramètre supplémentaire éventuel (null par défaut).

a. Note d'identification

La fonction de calcul de la note d'identification est :

fn_valid_auto_identification(p_id_synthese,p_code_liste,p_code_territoire,p_params)

Pour l'observation à noter, la fonction compare le cd_ref de l'espèce associés et la technique d'observation avec le référentiel identification du groupe taxonomique spécifié et pour le territoire spécifié.

Si aucun référentiel n'est trouvé pour ce groupe taxonomique, une erreur est générée et la validation est stoppée pour cette observation.

Si aucune correspondance n'est trouvée dans le référentiel, une erreur est générée et la validation est stoppée pour cette observation.

b. Note de présence

La fonction de calcul de la note de présence est :

fn_valid_auto_presence(p_id_synthese, p_code_liste, p_code_territoire, p_params).

Une observation peut être un polygone et croiser plusieurs mailles ayant potentiellement des notes de présence différentes.

Pour l'observation à noter, la fonction cherche donc dans le référentiel de présence la note de toutes les mailles associées.

- Si toutes les mailles ont la même note → on prend cette note
- Si toutes les mailles n'ont pas la même note (P5 et P2) → P2

Si aucun référentiel n'est trouvé pour ce groupe taxonomique, une erreur est générée et la validation est stoppée pour cette observation.

Si aucune correspondance n'est trouvée dans le référentiel, une erreur est générée et la validation est stoppée pour cette observation.

Note : fonction à revoir si le référentiel est amené à contenir d'autres notes que P5 et P2.

c. Note de période d'observation

La fonction de calcul de la note de période d'observation est :

fn_valid_auto_periode(p_id_synthese, p_code_liste, p_code_territoire, p_params).

Pour l'observation à noter, la fonction cherche dans le référentiel de période les périodes favorables à l'observation pour le cd_ref et le territoire correspondant.

L'algorithme tient compte de la possibilité d'avoir plusieurs périodes favorables. Si au moins une période est trouvée :

- Si la date d'observation est le 01/01 à 00:00:00 → cela correspond la plupart du temps à une donnée annuel donc : D1 (Date trop imprécise)
- Si l'intervalle d'observation est à cheval sur une période favorable → D1
- Si l'intervalle d'observation est en dehors de toute période favorable → D2
- Si l'intervalle d'observation est à l'intérieur d'au moins une période favorable → D3

Si aucun référentiel n'est trouvé pour ce groupe taxonomique, une erreur est générée et la validation est stoppée pour cette observation.

Si aucune période favorable n'est trouvée dans le référentiel, une erreur est générée et la validation est stoppée pour cette observation.

6. La fonction de traitement des notes de validation

La fonction de traitement des notes de validations est :

compute_validation_status(p_id_synthese, p_uuid, p_note_identification, p_note_periode, p_note_presence)

Cette fonction utilisée par la fonction centrale de validation d'une observation a pour but de calculer le statut de validation à partir des notes et d'intégrer cette validation dans geonature (historique et synthèse). Elle reçoit en entrées l'id_synthese de l'observation, son UUID ainsi que ses 3 notes. Les étapes de son fonctionnement sont :

- Calculer le statut de validation à partir des notes en utilisant le référentiel des statuts (ref_valid_auto).
- Récupérer les libellés des notes dans le référentiel des notes (ref_notes) pour la construction des commentaires de validation.
- Construire les commentaires de validation.
- Récupérer l'id_nomenclature_valid_status à partir des nomenclatures de géonature.
- Récupérer les données de validation actuelles de l'observation ainsi que son historique de validation.
- **Gestion détaillée des cas de validation :**

Le moteur de validation automatique utilise une logique fine. En particulier, la gestion des scénarios où une validation automatique **existe déjà** dans l'historique requiert une analyse précise de :

- Ce que **reflète réellement la synthèse** au moment du traitement ;
- La présence éventuelle de validations manuelles non-producteur ;
- La nécessité ou non de mettre à jour la synthèse.

Note : par convention nous appelons validation manuelle non_producteur toute validation manuelle réalisée par un expert (ou groupe d'experts) soit via le module de validation soit via la validation manuelle automatisée (lors de jeux complets par exemple). En opposition les validations manuelles producteur sont les validations fournies avec les données et intégrées lors de l'importation de celles-ci. 3 rôles sont dédiés à ces validations : producteur, régional et national.

Les règles complètes sont les suivantes :

1. Gestion de la mise à jour de la synthèse

Les triggers de mise à jour de la synthèse sont désactivées le temps du process de validation automatique afin d'accélérer l'exécution des scripts. Ils sont réactivés en fin de process.

Toutes les mises à jour qui doivent être reportées dans la synthèse sont stockées dans une table temporaire afin d'être réalisées en une seule opération en fin de process.

2. Définition de ce que reflète la synthèse

Avant de traiter les cas, la fonction identifie si la synthèse reflète :

a. Une validation automatique SFEPM

C'est le cas si :

- validator = 'Validation automatique SFEPM'

- Le statut présent dans la synthèse correspond au statut enregistré dans la dernière validation auto
- Le commentaire associé correspond également

b. Une validation manuelle non-producteur

C'est le cas si :

- Le validateur n'est **pas** automatique ni producteur, ni régional, ni national,
- La synthèse correspond exactement à la dernière validation manuelle non-producteur (statut, commentaire, date)

Cette distinction permet de savoir si la validation automatique doit ou non écraser la synthèse.

3. Cas 1 : première validation automatique

1.a. Synthèse ne reflète pas une validation manuelle non-producteur

(Aucune validation ou validations producteur uniquement)

→ insertion de la validation auto dans l'historique des validations + mise à jour de la synthèse (table temporaire).

1.b. Synthèse reflète une validation manuelle non-producteur

→ insertion de la validation auto dans l'historique des validations **sans mise à jour de la synthèse** (exclue de la table temporaire).

4. Cas 2 : Il existe déjà une validation automatique dans l'historique

2.a. La synthèse reflète déjà une validation automatique SFEPM

2.a.i. Les nouvelles notes/statut/commentaires sont identiques

→ Aucune action :

- Pas d'ajout dans l'historique
- Pas de modification de la synthèse

2.a.ii. Les nouvelles valeurs sont différentes

→ Insertion d'une nouvelle validation automatique dans t_validations

→ Mise à jour de la synthèse

2.b. La synthèse reflète une validation manuelle non-producteur

2.b.i. Nouvelles valeurs identiques à l'ancienne validation auto

→ Aucune action

- Pas de mise à jour synthèse
- Pas de nouvelle ligne auto

2.b.ii. Nouvelles valeurs différentes

→ Insertion d'une nouvelle validation auto

→ Synthèse non modifiée

(On respecte la validation manuelle en place.)

2.c. Cas résiduel (validation producteur, régional, national...)

- Insertion d'une nouvelle validation auto
- Synthèse non modifiée
- Alerte (warning) enregistrée dans warning_validations

5. Rôle des warnings dans les cas particuliers

Les warnings (valid_auto.log_warning) sont générés lorsque :

- Les données de synthèse ne correspondent ni à la dernière validation auto, ni à la dernière validation manuelle non-producteur ;
- Une incohérence est détectée dans l'historique ;
- Le moteur détecte un cas résiduel inhabituel.

Les warnings ne bloquent pas la validation : ils servent à **signaler des situations anormales**.

La fonction comporte des contrôles supplémentaires pour éviter des corruptions :

- Aucun historique trouvé alors qu'une auto est attendue → warning + abandon subi
- Validation manuelle non-producteur incohérente avec synthèse → warning.

Ces protections évitent des écritures incorrectes dans synthese ou t_validations.

La validation de l'observation est stoppée et des erreurs sont générées dans les cas suivants :

- Aucun statut trouvé dans ref_valid_auto pour les notes
- Impossible de trouver le libellé pour la note dans ref_notes
- Impossible de trouver l'id_nomenclature pour le statut
- Impossible de trouver l'id_synthese dans la synthese

7. La fonction centrale de validation d'une observation

Il s'agit de la fonction que l'on va appliquer à l'observation à valider. Elle se nomme :

apply_valid_auto(p_id_synthese, p_uuid)

Elle reçoit donc en entrée uniquement l'id_synthese et l'UUID de l'observation et réalise les actions suivantes :

- Récupération du groupe taxonomique de validation à partir du cd_nom
- Récupération du territoire d'appartenance à partir de la table cor_area_synthese
- Exécution des fonctions de calcul des notes
- Intégration ou mise à jour des notes dans la table **calculated_notes**
- Exécution de la fonction de traitement des notes **compute_validation_status**

8. La fonction globale de validation par séries

C'est la fonction englobante que l'on va appeler lors d'une procédure de validation automatique. Elle se nomme :

run_validation_batch(p_filter_field, p_filter_value)

Elle reçoit en entrées le champ de la synthèse à filtrer et la valeur que doit prendre ce champ. Exemples :

Si on veut appliquer la validation automatique à un jeu de donnée (id_dataset = 144) on exécutera **run_validation_batch('id_dataset',144)**

Si on veut appliquer la validation automatique aux données importées à partir du module d'import (id_import = 166) on exécutera **run_validation_batch('id_import',166)**

Une variante **run_validation_batch_by_group(p_code_liste)** permet d'appliquer la validation au groupe taxonomique en entier.

Ex : **run_validation_batch_by_group('valid_auto_petits_mams')**

Ces fonctions ne filtrent par défaut que les observations de présence

Elles réalisent les actions suivantes :

- Récupérer les observations à valider depuis la synthèse en fonction du filtre.
- Exécuter la validation automatique (apply_valid_auto) pour chaque observation.
- Compter et enregistrer les alertes générées par les validations.
- Compter et enregistrer les erreurs générées lors des validations.
- Mettre à jour la synthèse à partir de la table temporaire.
- Enregistrer les reporting dans les tables **report_validations**, **error_validations** et **warning_validations**.

9. Le reporting

Lors d'une session de validation automatique 3 tables de reporting sont alimentées :

- **Report_validations** : Cette table affecte un identifiant (id_report) à la session et fournit les statistiques de bases :
 - Date
 - Champ et valeur utilisés pour le filtre dans la fonction run_validation_batch
 - Le nombre d'observations à valider
 - Le nombre d'observations validées
 - Le nombre d'erreurs
 - Le nombre d'alertes

- **Error_validations** : Cette table référence les observations de la session n'ayant pas été validées. Dans ces cas une erreur a été générée lors du processus de validation. Les informations concernant ces erreurs sont conservées ici :
 - Id_report
 - Id_synthese
 - Date
 - Type d'erreur
 - Message de l'erreur
 - Contexte
- **Warning_validations** : Cette table conserve les alertes générées lors de la validation mais n'ayant pas entraîné d'erreur. La validation a été réalisée avec succès mais certaines incohérences ont été signalées. Les informations gardées sont :
 - Id_report
 - Id_synthese
 - Date
 - Message de l'alerte
 - Contexte

Codes fournis en annexe :

- Fonction **find_cdref_es**(cd_nom)
- Fonction **find_all_cdref_childs_liste** (id_liste)
- Vue **v_cor_cdref_grp_valid_auto**(code_liste, cd_ref)
- Vue **v_territoires_france**(area_code)
- Fonction **run_validation_batch**(p_filter_field, p_filter_value **integer**)
- Fonction **run_validation_batch**(p_filter_field, p_filter_value **text**)
- Fonction **run_validation_batch_by_group**(p_code_liste)
- Fonction **fn_valid_auto_identification**(p_id_synthese, p_code_liste, p_code_territoire, p_params)
- Fonction **fn_valid_auto_presence**(p_id_synthese, p_code_liste, p_code_territoire, p_params)
- Fonction **fn_valid_auto_periode**(p_id_synthese, p_code_liste, p_code_territoire, p_params)
- Fonction **apply_valid_auto** (p_id_synthese, p_uuid)
- Fonction **compute_validation_status**(p_id_synthese, p_uuid, p_note_identification, p_note_periode, p_note_presence)
- Fonction **log_warning**(p_id_synthese, p_message, p_context)